

EL CONTEXTO ENTRE ÉPOCAS MANDA: ESTADIFICACIÓN DEL SUEÑO DESDE UN SMARTWATCH

Agustín A. Pereyra • Agustín Patruno

Departamento de Ingeniería — Universidad de San Andrés, Buenos Aires
apereyra@udesa.edu.ar • apatruno@udesa.edu.ar

Resultado principal

+12
pts κ

Una **BiLSTM** sobre features por época ($\kappa \approx 0.46$, $F1_{\text{macro}} \approx 0.57$) supera a los baselines tabulares por **~12 puntos de Cohen's κ** . El factor decisivo no es el clasificador ni la señal cruda: es la **dependencia temporal entre épocas**.

El problema · De la polisomnografía a la muñeca

La estadificación del sueño —asignar una etapa a cada época de **30 s** según el estándar clínico AASM— es clave para diagnosticar apnea o insomnio, pero hoy exige **polisomnografía**: cara, incómoda y de laboratorio. Un Smart-Watch mide de forma continua y no invasiva.


Entrada: IHR (frecuencia cardíaca instantánea) + acelerometría triaxial de un Apple Watch.

Salida: etapa por época — Wake · N1 · N2 · N3 · REM.

Wake N1 N2 N3 REM

Datos · 47 adultos, 253 noches (PhysioNet BIDSleep)

Etiquetas de dos fuentes: un **experto** en polisomnografía (ground-truth, AASM) y un dispositivo **Dreem** basado en EEG (referencia y competencia directa; acuerdo experto–Dreem $\kappa \approx 0.72$). Clases fuertemente **desbalanceadas** — de ahí evaluar con $F1_{\text{macro}}$ y usar costo ponderado por clase.



Limpieza de señal · pipeline estricto y

Metodología · Progresión de modelos

Comparamos una progresión pensada para **aislar el aporte del contexto inter-época**:


BASELINE — **XGBoost & MLP**. 122 features handcrafted por época; clasifican cada época de forma **aislada**.

GANADOR — **BiLSTM** (**many-to-many**). Recorre la noche entera sobre las mismas features $\Rightarrow$ modela la **dinámica inter-época**.

HÍBRIDO — **CNN1D $\rightarrow$ BiLSTM**. La CNN aprende la época desde la **señal cruda** (150×4); la BiLSTM la secuencia. End-to-end.

Redes entrenadas con **cross-entropy ponderada por clase** e hiperparámetros por **búsqueda bayesiana (TPE / Optuna)**, optimizando κ de validación. Split por paciente (33/7/7) para evitar leakage.

Resultados · κ frente al experto (5 clases)



Cohen's $\kappa = (p_o - p_e) / (1 - p_e)$. La BiLSTM lidera también en AUC-ROC (0.84) y AP (0.60).

Rendimiento en test

Modelo	$F1_M$	$\kappa(5cl)$	$\kappa(4cl)$	Acc.
Dreem	0.71	0.72	0.80	0.79

El hallazgo · Tres evidencias convergentes


El contexto temporal **inter-época** es el factor determinante — no el modelo ni la representación de la señal:

1. La BiLSTM suma **+12 pts de κ** sobre los baselines usando **las mismas features**. Lo único nuevo es la secuencia.

2. Los valores **SHAP** muestran que hasta el XGBoost se apoya en features de contexto (posición en la noche, estadísticos móviles).

3. Una **CNN sobre señal cruda, sin contexto**, rinde **cerca del azar** ($\kappa \approx 0.04$). Lo intra-época, solo, no alcanza.

Resultado cualitativo · una noche reconstruida



Paciente 31: la BiLSTM reproduce la macroestructura del hipnograma del experto —bloques de N2/Deep y REM al final—; el híbrido fragmenta más y sobre-predice Wake.

Dónde falla · matriz de confusión BiLSTM