

Del EEG a la muñeca: estadificar el sueño con un SmartWatch

Agustín A. Pereyra · Agustín Patruno

Depto. de Ingeniería – Universidad de San Andrés, Buenos Aires · apereyra@udesa.edu.ar · apatruno@udesa.edu.ar



RESUMEN

Predecir la etapa del sueño en cada época de 30 s usando **sólo** el pulso y el movimiento de un reloj. Una **BiLSTM** que recorre la noche entera le gana a los clasificadores por época en **~12 puntos de Cohen's κ** . La clave no es el modelo ni la señal cruda: es el **contexto temporal entre épocas**.

0.46 0.57 0.84
 K VS EXPERTO F_1 MACRO AUC-ROC

01 Motivación

- La **estadificación del sueño** —una etapa por época de 30 s— es la base para diagnosticar **apnea**, **insomnio** y otros trastornos.
- Hoy exige **polisomnografía**: EEG, EOG y EMG en un laboratorio. Es **cara**, **incómoda y de una sola noche**.
- Un **SmartWatch** mide pulso y movimiento de forma **continua**, **no invasiva y en casa** → monitoreo accesible y prolongado.

Entrada: IHR + acelerometría → Salida: etapa / época

02 Datos — BIDSleep


47 253 30 s 203.938
PACIENTES NOCHES P/ ÉPOCA TOTAL ÉPOCAS

- Adultos sanos, Apple Watch Series 6 (PhysioNet). Dos señales crudas por época:
- IHR** (*instantaneous heart rate*) — frecuencia cardíaca latido a latido derivada del fotopletismógrafo; refleja la actividad autonómica del sueño.
 - Acelerometría de 3 ejes** (x, y, z) — movimiento de la muñeca; captura inquietud, cambios posturales y micro-movimientos.

Y dos etiquetas por época:

- Experto** (AASM) — *ground-truth*.
- Dreem** (headband EEG) — referencia y competidor (acuerdo $\kappa \approx 0.72$).

DISTRIBUCIÓN DE ETAPAS · CLASES DESBALANCEADAS



03 Features

122 / época

Cada época de 30 s se resume en un vector de **122 features** *handcrafted* guiadas por el dominio, computadas **dentro** de la época y sobre su **contexto temporal**.

INTRA-ÉPOCA · DENTRO DE LOS 30 S

- IHR / HRV**: nivel y dispersión (media, mediana, IQR, rango) + variabilidad cardíaca en el tiempo (**RMSSD**, **pNN50** sobre intervalos RR / NN) + pendiente.
- Acelerometría**: sobre la **magnitud** $\|a\|$ (invariante a la orientación) y el **ENMO** = $\max(\|a\| - 1, 0)$: media, desvío, rango, fracción de inmovilidad y *jerk*.

INTER-ÉPOCA · CONTEXTO TEMPORAL

- `epoch_frac` (posición en la noche) y `epochs_since_move`.
- Lags y leads*, diferencias (*deltas*) y estadísticos de **ventana móvil** de cada feature, respetando los bordes de la noche.


PREPARACIÓN

- Señales **resampleadas** a una grilla común, **estandarizadas** (z-score) y alineadas con la época; el vector alimenta a **XGBoost / MLP / BiLSTM**.

04 Método — BiLSTM

BiLSTM many-to-many sobre las 122 features: recorre la noche completa hacia adelante y hacia atrás, así cada época integra contexto **pasado y futuro**.

0 Sensor · Apple Watch




1 Señales crudas




2 Vector de features x_t



3 BiLSTM many-to-many



4 Predicción por época



★ Estadificación en 4 clases

Colapsando N1+N2 en **Light** y N3 en **Deep**, la tarea se reduce a las **cuatro clases** clínicas estándar:



4 CLASES · COMPARACIÓN


	ACCURACY	WT. F1
SLAMSS-IFS (paper)	0.71	0.71
BiLSTM (nuestro)	0.65	0.65

05 Resultados

test · vs experto


MODELO	F_1^M	K_5	K_4	ACC
Dreem	0.71	0.72	0.80	0.79
XGBoost	0.44	0.32	0.34	0.51
MLP	0.45	0.35	0.36	0.53
BiLSTM	0.57	0.46	0.49	0.59
Híbrido	0.48	0.36	0.39	0.48

COHEN'S K (5 CLASES) VS. EXPERTO



Los baselines por época empatan ($\kappa \approx 0.32$ – 0.35); la **BiLSTM salta a $\kappa \approx 0.46$** con las *mismas* features. El **híbrido** sobreajusta su encoder. La brecha con Dreem se concentra en **N1** y en las transiciones.

06 Reconstrucción de una noche




Paciente 31: la **BiLSTM** reproduce la macroestructura del hipnograma del experto —bloques de N2/N3 y REM hacia el final—; el híbrido fragmenta y sobre-predice Wake.

Wake N1 N2 N3 REM

07 Trabajo futuro

ALTERNATIVA · HÍBRIDO CNN1D → BiLSTM



Una **CNN 1D** aprende la representación de cada época desde la **señal cruda**, *end-to-end*. Sin preentrenamiento el encoder **sobreajusta** → no supera al enfoque tabular.

REFERENCIA · SLAMSS-IFS

El modelo del paper original es un **seq2seq LSTM con capas convolucionales** que estadifica las 4 clases desde IHR y acelerometría de 3 ejes **crudas**. Sus innovaciones (**IFS**): LSTM de **aprendizaje intra-época**, **información en frecuencia** y **skip connections** —y recupera el sueño profundo subrepresentado (~0.71 acc / 0.71 F1).

QUÉ INCORPORAR A NUESTRO MODELO

- LSTM intra-época**: aprender la representación dentro de cada época de 30 s en vez de 122 features tabulares (nuestra CNN 1D sobreajustó).
- Información en frecuencia**: sumar el espectro de IHR/aceler al dominio temporal.
- Skip connections** para entrenar un encoder profundo sin degradar el gradiente.
- Capa de atención**: pondera qué épocas y timesteps pesan más en cada predicción; nuestra BiLSTM trata todo el contexto por igual, y la atención le permitiría enfocarse en las **transiciones** entre etapas.

08 Conclusiones

Un *pipeline* completo de sleep staging desde la muñeca —sin EEG— muestra que el factor determinante es la **dependencia temporal inter-época**, por encima del clasificador y de la representación de la señal.

Modelando la **secuencia de la noche**, la BiLSTM se acerca al techo humano; el límite que queda es la **señal** (muñeca vs. EEG), no el modelo. El monitoreo prolongado del sueño desde la muñeca es viable como *screening*.

REFERENCIAS

- Song, Zhang, Zhou, Hou, Malekzadeh, Behzad & Dutta. AI-Driven Sleep Staging Using Instantaneous Heart Rate and Accelerometry: Insights From an Apple Watch Study. IEEE Trans. Biomed. Eng., 2026 · SLAMSS-IFS.
- Song, Chowdhury, Malekzadeh, Harrison, Hoge, Redline, Stone, Saxena, Purcell & Dutta. AI-Driven Sleep Staging from Actigraphy and Heart Rate. PLOS ONE, 2023 · SLAMSS.
- Song. A Multi-Night Instantaneous Heart Rate and Accelerometry Dataset with EEG Sleep Stage Labels. PhysioNet, 2026 · BIDSleep v1.0.0.
- Hochreiter & Schmidhuber. Long Short-Term Memory. Neural Computation, 1997.
- Schuster & Paliwal. Bidirectional Recurrent Neural Networks. IEEE Trans. Signal Process., 1997.
- Cohen. A Coefficient of Agreement for Nominal Scales. Educ. Psychol. Meas., 1960.
- Landis & Koch. The Measurement of Observer Agreement for Categorical Data. Biometrics, 1977.
- Chen & Guestrin. XGBoost: A Scalable Tree Boosting System. ACM SIGKDD, 2016.
- Lundberg & Lee. A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017 · SHAP.
- Bergstra, Bardenet, Bengio & Kégl. Algorithms for Hyper-Parameter Optimization. NeurIPS, 2011 · TPE.