

# Del EEG a la muñeca: estadificar el sueño con un SmartWatch

Agustín A. Pereyra · Agustín Patruno

Depto. de Ingeniería – Universidad de San Andrés, Buenos Aires · apereyra@udesa.edu.ar · apatruno@udesa.edu.ar



## RESUMEN

Predecir la etapa del sueño en cada época de 30 s usando **sólo** el pulso y el movimiento de un reloj. Una **BiLSTM** que recorre la noche entera le gana a los clasificadores por época en **~12 puntos de Cohen's  $\kappa$** . La clave no es el modelo ni la señal cruda: es el **contexto temporal entre épocas**.

0.460.570.84  
K VS EXPERTO F<sub>1</sub> MACRO AUC-ROC

### 01 Motivación

- La **estadificación del sueño** —una etapa por época de 30 s— es la base para diagnosticar **apnea**, **insomnio** y otros trastornos.
- Hoy exige **polisomnografía**: EEG, EOG y EMG en un laboratorio. Es **cara, incómoda y de una sola noche**.
- Un **SmartWatch** mide pulso y movimiento de forma **continua, no invasiva y en casa** → monitoreo accesible y prolongado.

Entrada: IHR + acelerometría → Salida: etapa / época

### 02 Datos — BIDSleep

4725330 s203.938  
PACIENTES NOCHES P/ ÉPOCA TOTAL ÉPOCAS


Adultos sanos, Apple Watch Series 6 (PhysioNet). Dos señales crudas por época:

- IHR** (*instantaneous heart rate*) — frecuencia cardíaca latido a latido derivada del fotopletismógrafo; refleja la actividad autonómica del sueño.
- Acelerometría de 3 ejes** (x, y, z) — movimiento de la muñeca; captura inquietud, cambios posturales y micro-movimientos.

Y dos etiquetas por época:

- Experto** (AASM) — *ground-truth*.
- Dreem** (headband EEG) — referencia y competidor (acuerdo  $\kappa \approx 0.72$ ).

DISTRIBUCIÓN DE ETAPAS · CLASES DESBALANCEADAS



### 03 Features

122 / época

Cada época de 30 s se resume en un vector de **122 features** *handcrafted* guiadas por el dominio, computadas **dentro** de la época y sobre su **contexto temporal**.

INTRA-ÉPOCA · DENTRO DE LOS 30 S

- IHR / HRV**: nivel y dispersión (media, mediana, IQR, rango) + variabilidad cardíaca en el tiempo (**RMSSD**, **pNN50** sobre intervalos RR / NN) + pendiente.
- Acelerometría**: sobre la **magnitud**  $\|a\|$  (invariante a la orientación) y el **ENMO** =  $\max(\|a\| - 1, 0)$ : media, desvío, rango, fracción de inmovilidad y *jerk*.

INTER-ÉPOCA · CONTEXTO TEMPORAL

- `epoch_frac` (posición en la noche) y `epochs_since_move`.
- Lags* y *leads*, diferencias (*deltas*) y estadísticos de **ventana móvil** de cada feature, respetando los bordes de la noche.

PREPARACIÓN

- Señales **resampleadas** a una grilla común, **estandarizadas** (z-score) y alineadas con la época; el vector alimenta a **XGBoost / MLP / BiLSTM**.


### 04 Método — BiLSTM

**BiLSTM many-to-many** sobre las 122 features: recorre la noche completa hacia adelante y hacia atrás, así cada época integra contexto **pasado y futuro**.

#### 0 Sensor · Apple Watch




#### 1 Señales crudas



#### 2 Vector de features x<sub>t</sub>




#### 3 BiLSTM many-to-many



$$\mathcal{L} = - \sum_c w_c y_c \log \hat{y}_c$$

$w_c \propto 1/f_c$  · cross-entropy ponderada – entrena la BiLSTM

#### 4 Predicción por época



### ★ Estadificación en 4 clases

Colapsando N1+N2 en **Light** y N3 en **Deep**, la tarea se reduce a las **cuatro clases** clínicas estándar:



4 CLASES · COMPARACIÓN


|                         | ACCURACY    | WT. F1      |
|-------------------------|-------------|-------------|
| SLAMSS-IFS (paper)      | 0.71        | 0.71        |
| <b>BiLSTM (nuestro)</b> | <b>0.65</b> | <b>0.65</b> |

### 05 Resultados

test · vs experto


| MODELO        | F <sub>1</sub> <sup>M</sup> | K5          | K4          | ACC         |
|---------------|-----------------------------|-------------|-------------|-------------|
| Dreem         | 0.71                        | 0.72        | 0.80        | 0.79        |
| XGBoost       | 0.44                        | 0.32        | 0.34        | 0.51        |
| MLP           | 0.45                        | 0.35        | 0.36        | 0.53        |
| <b>BiLSTM</b> | <b>0.57</b>                 | <b>0.46</b> | <b>0.49</b> | <b>0.59</b> |
| Híbrido       | 0.48                        | 0.36        | 0.39        | 0.48        |

COHEN'S K (5 CLASES) VS. EXPERTO



Los baselines por época empatan ( $\kappa \approx 0.32$ – $0.35$ ); la **BiLSTM salta a  $\kappa \approx 0.46$**  con las *mismas* features. El **híbrido** sobreajusta su encoder. La brecha con Dreem se concentra en **N1** y en las transiciones.

### 06 Reconstrucción de una noche




Paciente 31: la **BiLSTM** reproduce la macroestructura del hipnograma del experto —bloques de N2/N3 y REM hacia el final—; el híbrido fragmenta y sobre-predice Wake.

Wake N1 N2 N3 REM

### 07 Trabajo futuro

ALTERNATIVA · HÍBRIDO CNN1D → BiLSTM



Una **CNN 1D** aprende la representación de cada época desde la **señal cruda**, *end-to-end*. Sin preentrenamiento el encoder **sobreajusta** → no supera al enfoque tabular.

REFERENCIA · SLAMSS-IFS

El modelo del paper original es un **seq2seq LSTM** con **capas convolucionales** que estadifica las 4 clases desde IHR y acelerometría de 3 ejes **crudas**. Sus innovaciones (**IFS**): LSTM de **aprendizaje intra-época**, **información en frecuencia** y **skip connections** —y recupera el sueño profundo subrepresentado (~0.71 acc / 0.71 F1).

QUÉ INCORPORAR A NUESTRO MODELO

- LSTM intra-época**: aprender la representación dentro de cada época de 30 s en vez de 122 features tabulares (nuestra CNN 1D sobreajustó).
- Información en frecuencia**: sumar el espectro de IHR/aceler al dominio temporal.
- Skip connections** para entrenar un encoder profundo sin degradar el gradiente.
- Capa de atención**: pondera qué épocas y timesteps pesan más en cada predicción; nuestra BiLSTM trata todo el contexto por igual, y la atención le permitiría enfocarse en las **transiciones** entre etapas.

### 08 Conclusiones

Un *pipeline* completo de sleep staging desde la muñeca —sin EEG— muestra que el factor determinante es la **dependencia temporal inter-época**, por encima del clasificador y de la representación de la señal.

Modelando la **secuencia de la noche**, la BiLSTM se acerca al techo humano; el límite que queda es la **señal** (muñeca vs. EEG), no el modelo. El monitoreo prolongado del sueño desde la muñeca es viable como *screening*.

#### REFERENCIAS

- Song, Zhang, Zhou, Hou, Malekzadeh, Behzad & Dutta. AI-Driven Sleep Staging Using Instantaneous Heart Rate and Accelerometry: Insights From an Apple Watch Study. IEEE Trans. Biomed. Eng., 2026 · SLAMSS-IFS.
- Song, Chowdhury, Malekzadeh, Harrison, Hoge, Redline, Stone, Saxena, Purcell & Dutta. AI-Driven Sleep Staging from Actigraphy and Heart Rate. PLOS ONE, 2023 · SLAMSS.
- Song. A Multi-Night Instantaneous Heart Rate and Accelerometry Dataset with EEG Sleep Stage Labels. PhysioNet, 2026 · BIDSleep v1.0.0.
- Hochreiter & Schmidhuber. Long Short-Term Memory. Neural Computation, 1997.
- Schuster & Paliwal. Bidirectional Recurrent Neural Networks. IEEE Trans. Signal Process., 1997.
- Cohen. A Coefficient of Agreement for Nominal Scales. Educ. Psychol. Meas., 1960.
- Landis & Koch. The Measurement of Observer Agreement for Categorical Data. Biometrics, 1977.
- Chen & Guestrin. XGBoost: A Scalable Tree Boosting System. ACM SIGKDD, 2016.
- Lundberg & Lee. A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017 · SHAP.
- Bergstra, Bardenet, Bengio & Kégl. Algorithms for Hyper-Parameter Optimization. NeurIPS, 2011 · TPE.