




¿Tu Apple Watch identifica bien las etapas de tu sueño? estadificación del sueño con un SmartWatch

APAREYRA, ARIEL · APARTRUNO, RAFAEL

Departamento de Ingeniería — Universidad de San Andrés, Buenos Aires
apereyra@udesa.edu.ar · apatruno@udesa.edu.ar



+12 pts κ

Una **BiLSTM** sobre features por época ($\kappa \approx 0.46$, $F1_{\text{macro}} \approx 0.57$) supera a los baselines tabulares por **~12 puntos de Cohen's κ** . El factor decisivo no es el clasificador ni la señal cruda: es la **dependencia temporal entre épocas**.

EL PROBLEMA

De la polisomnografía a la muñeca

La estadificación del sueño —asignar una etapa a cada época de **30 s** según el estándar clínico AASM— es clave para diagnosticar apnea o insomnio, pero hoy exige **polisomnografía**: cara, incómoda y de laboratorio.

Un SmartWatch mide de forma continua y no invasiva. Nuestro objetivo: predecir la etapa desde señales de muñeca.

IN IHR (frecuencia cardíaca instantánea) + **acelerometría** triaxial de un Apple Watch

OUT Etapa por época: **Wake · N1 · N2 · N3 · REM**


Wake N1 N2 N3 REM

DATOS · PHYSIONET BIDSLEEP

47 adultos · 253 noches

Etiquetas de dos fuentes: un **experto** en polisomnografía (ground-truth, AASM) y un dispositivo **Dreem** basado en EEG (referencia y competencia directa, acuerdo experto–Dreem $\kappa \approx 0.72$).


Clases fuertemente **desbalanceadas** — de ahí evaluar con $F1_{\text{macro}}$ y usar costo ponderado por clase:



LIMPIEZA DE SEÑAL

Un pipeline estricto y reproducible

- Corrección de **desalineación temporal** (zona horaria local vs. Unix UTC) y filas corruptas.
- Ventana válida** = intersección del rango etiquetado n IHR continuo n acelerometría continua.
- Gaps** internos: recorte de cola o descarte de noche; dropouts dispersos filtrados por época.
- Misma fuente de verdad para las **3 rutas** de datos → comparación honesta entre modelos.



Noche procesada (Paciente 20): en verde la ventana válida, en rojo la zona descartada.

APÉNDICE · REPRESENTACIÓN NO SUPERVISADA

¿Aprender la representación sin etiquetas?

Un **autoencoder LSTM** comprime cada noche en un embedding por época (L=32) reconstruyendo las features **sin usar etiquetas**; un XGBoost clasifica sobre él. ¿Supera al feature engineering de dominio?

ENTRADA	XGBOOST	$F1_M$	K (5CL)	K (4CL)
Handcrafted (122)		0.47	0.38	0.39
Embeddings (32)		0.40	0.29	0.29
Ambas (154)		0.47	0.38	0.38

No: los embeddings quedan por debajo de las features handcrafted ($\Delta\kappa \approx -0.09$) y sumarlos no aporta ($\Delta\kappa \approx -0.001$). En esta tarea, el conocimiento de dominio le gana a la representación no supervisada.

METODOLOGÍA · PROGRESIÓN DE MODELOS

Del baseline por época al contexto secuencial

Comparamos una progresión pensada para **aislar el aporte del contexto inter-época**:

BASELINE XGBoost & MLP
122 features handcrafted por época. Clasifican cada época de forma **aislada**.


GANADOR BiLSTM (many-to-many)
Recorre la noche entera sobre las mismas features → modela la

HÍBRIDO CNN1D → BiLSTM
CNN aprende la época desde la **señal cruda** (150×4); BiLSTM la secuencia. End-to-end.

Redes entrenadas con **cross-entropy ponderada por clase** e hiperparámetros por **búsqueda bayesiana (TPE / Optuna)**, optimizando κ de validación. Split **por paciente** (33 / 7 / 7) para evitar leakage.

RESULTADOS · K FRENTE AL EXPERTO (5 CLASES)

El salto de la BiLSTM



Cohen's $\kappa = (p_o - p_e) / (1 - p_e)$. La BiLSTM lidera también en AUC-ROC (0.84) y AP (0.60).

RENDIMIENTO EN TEST

MODELO	$F1_M$	K (5CL)	K (4CL)	ACC.
Dreem	0.71	0.72	0.80	0.79
XGBoost	0.44	0.32	0.34	0.51
MLP	0.45	0.35	0.36	0.53
BiLSTM	0.57	0.46	0.49	0.59
Híbrido	0.48	0.36	0.39	0.48

Al agrupar en 4 clases (Light / Deep) todas las métricas suben y el orden se mantiene: la ventaja del contexto no depende de la granularidad. La brecha residual con Dreem se concentra en N1 y en las transiciones — límite intrínseco de la muñeca frente al EEG.


CALIDAD DEL RANKING · TEST (ONE-VS-REST, 5 CL.)

CURVA (MACRO)	XGB	MLP	BILSTM	HÍBR.
AUC-ROC	0.77	0.78	0.84	0.83
AP (PR)	0.49	0.50	0.60	0.57

La BiLSTM lidera también en el **ranking de probabilidades**, no solo en la decisión: el contexto inter-época mejora la confianza asignada a cada etapa, no únicamente el umbral de corte.

APÉNDICE · INTERPRETABILIDAD (SHAP)

Hasta el baseline mira el tiempo



Importancia SHAP del XGBoost por etapa: dominan *epoch_frac*, estadísticos móviles (*_rstd*) y *epochs_since_move* — todas de contexto temporal.

EL HALLAZGO


Tres evidencias convergentes

El contexto temporal es el factor determinante — no el modelo ni la representación de la señal:

- La BiLSTM suma sobre los baselines usando. Lo único nuevo es la secuencia.
- Los valores muestran que hasta el XGBoost se apoya en features de contexto (posición en la noche, estadísticos móviles).
- Una ($\kappa \approx 0.04$). Lo intra-época, solo, no alcanza.

RESULTADO CUALITATIVO

Una noche reconstruida



Paciente 31: la BiLSTM reproduce la macroestructura del hipnograma del experto — bloques de N2/Deep y REM al final—; el híbrido fragmenta más y sobre-predice Wake.

DÓNDE FALLA

Matriz de confusión — BiLSTM (4 clases)

		LSTM (4 clases)			
expert label	Wake	1946	924	178	313
	Light	572	8940	2107	2638
	Deep	48	763	4671	172
	REM	67	2257	227	3671
		Wake	Light	Deep	REM
		predicted label			

Diagonal marcada; el error residual vive en la frontera **Light-REM** (sin EEG, REM ≈ sueño ligero). Deep es la clase mejor resuelta por su firma nítida: IHR mínimo e inmovilidad.

CONCLUSIÓN & TRABAJO FUTURO

Hacia el estado del arte

Un pipeline completo de sleep staging desde la muñeca confirma que **la dependencia inter-época domina**. El híbrido no superó al enfoque tabular por el sobreajuste de su encoder entrenado de cero.

- Intra-época**: reemplazar el encoder supervisado por **preentrenamiento auto-supervisado** (autoencoders) para un embedding más robusto.
- Inter-época**: sustituir la recurrencia por **auto-atención (Transformers)** para dependencias de largo alcance.

La referencia a seguir, **SLAMSS-IFS**, combina ambas y supera a nuestra BiLSTM por apenas ~5% de accuracy (4 clases).

REFERENCIAS SELECCIONADAS

[BIDSleep] PhysioNet BIDSleep Dataset v1.0.0 · [LSTM] Hochreiter & Schmidhuber, 1997 · [BiLSTM] Schuster & Paliwal, 1997 · [SLAMSS] 2023 · [TPE] Bergstra et al., 2011 · [Optuna] Akiba et al., 2019 · [SHAP] Lundberg & Lee, 2017. Librerías: PyTorch, scikit-learn, XGBoost, Optuna.

MENSAJE CLAVE

Con solo una muñeca —sin EEG— y modelando la **secuencia de la noche**, una BiLSTM se acerca de forma razonable al techo humano. El límite ya no es el clasificador: es **la señal**.

0.46 0.57 0.84
K VS. EXPERTO F1 MACRO AUC-ROC