

Predicción de Etapas del Sueño sobre señales Fisiológicas capturadas con SmartWatch

Agustín Adrián Pereyra
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apereyra@udesa.edu.ar

Agustín Patruno
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apatruno@udesa.edu.ar

Resumen—

Index Terms—sleep staging, recurrent neural networks, heart rate variability, accelerometry, EEG, deep learning

I. INTRODUCCIÓN

Frente a la polisomnografía –costosa y confinada al laboratorio–, los dispositivos *smart-watch* son capaces de registrar IHR (*Instantaneous Heart Rate*) y acelerometría de forma continua y no invasiva, habilitando el monitoreo domiciliario.

La *estadificación del sueño* (*sleep staging*) –asignar una etapa a cada época de 30 s de registro, según el estándar clínico AASM– es central para el diagnóstico de trastornos como la apnea o el insomnio, pero hoy depende de la polisomnografía y de la anotación manual de un experto, lo que la vuelve cara e incómoda. Lograrla a partir de señales de muñeca abriría la puerta a un monitoreo accesible y prolongado en el tiempo.

Abordamos la tarea como un problema de **clasificación multiclase supervisada**. La entrada de nuestro algoritmo es la IHR y la acelerometría triaxial de una época de 30 s (o su secuencia a lo largo de la noche), y utilizamos modelos de aprendizaje automático desde un *baseline* tabular (XGBoost, MLP) hasta modelos secuenciales que utilizan la señal cruda (BiLSTM y un híbrido CNN–BiLSTM) para predecir la etapa del sueño. Como referencia se emplean las etiquetas de un experto (*ground-truth*) y una referencia secundaria (y como nuestra competencia) las etiquetas de un dispositivo Dreem Headband, basado en EEG (electroencefalograma). El eje del trabajo es comparar esta progresión de modelos para cuantificar el aporte del **contexto temporal inter-época** –la dependencia entre etapas contiguas– frente a la clasificación de cada época de forma aislada.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

PhysioNet BIDSleep [1] recopila señales fisiológicas tales como la frecuencia cardíaca instantánea (IHR) y tres ejes de acelerometría medidas con un Apple Watch a lo largo de 253 noches de 47 adultos sanos. Cada lapso de 30 segundos se encuentra etiquetado por dos fuentes diferentes (*expert* y *dreem*) con una etapa del sueño:

0. **Wake** (Despierto)

1. **N1** (Sueño Ligero): etapa más superficial y la entrada al sueño. Suele ser la clase más difícil de detectar dado que es breve e inestable.
2. **N2** (Sueño Ligero consolidado): sujeto dormido de forma estable. Es la etapa más frecuente.
3. **N3** (Sueño profundo): el sueño mas reparador. En él cuesta mucho despertar al paciente. Debería mostrar IHR mínimo y cuerpo inmóvil
4. **REM** (*Rapid Eye Movement*): también llamado “sueño paradójico”. El EEG se parece al de vigilia pero el paciente está profundamente dormido, involucrando IHR irregular.

Podemos observar un ejemplo de todos los datos contenidos en una noche en la Figura 1.




Figura 1. Ejemplo de la entrada del algoritmo: señales (IHR y acelerometría) e hipnograma de una noche completa (Paciente 00, Noche 1).

A la hora de particionar el conjunto para el entrenamiento se realiza **por paciente** evitando así *leakage* y midiendo la generalización a sujetos nuevos. Se emplean dos representaciones: una **tabular** de 122 *features* por época y la **señal cruda** 150×4 en secuencias por noche, ambas estandarizadas con estadísticos de *train*; los modelos densos imputan a la mediana los NaN de borde. El IHR se muestrea a $\approx 0,2$ Hz (Nyquist $\approx 0,1$ Hz), por debajo de las bandas LF/HF (0,04–0,4 Hz), que resultan inobservables.

Antes de modelar se aplica un control de calidad noche a noche. Sobre cada noche se computan *gaps* temporales en IHR

y acelerometría ($> 60s$ entre muestras), duración de la señal y fracción de acelerometría inválida ($||a|| - 1| > 0,5g$), y se define la **ventana válida** como la intersección entre el rango etiquetado y el de IHR *continua*. Los desajustes se clasifican en *signal_excess* (señal sin etiqueta, se recorta), *label_trunc* (etiqueta sin señal, se recorta) e *internal_gap* (huecos > 10 min). Estos últimos, verificados como *dropouts* reales del sensor, se resuelven recortando la cola si el prefijo limpio supera el 60 % o descartando la noche. Todo se aplica en memoria, sin alterar los archivos originales.

III. METODOLOGÍA

III-A. Métricas de Rendimiento

Dado que se tienen dos criterios para tomar como *ground-truth* (etiquetas del experto y del dispositivo Dreem) usamos el **coeficiente Cohen's Kappa** [2] para cuantificar cuán de acuerdo están entre sí. [3]

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (1)$$

El desempeño de clasificación se mide con el **F1-score macro** —media del F1 por clase, que al pesar todas las etapas por igual es la métrica más honesta bajo el desbalance—, complementado con la **accuracy** global y la **matriz de confusión**, que localiza entre qué etapas ocurren los errores.

III-B. Elección de modelos

Como **baseline** se usa **XGBoost** sobre *features* por época: modelo tabular robusto, que maneja valores faltantes de forma nativa y da importancia interpretable. Las *features* resumen IHR y HRV en el dominio temporal (RMSSD, pNN50, etc.) y la acelerometría sobre la magnitud $||a||$ —invariante a la orientación del reloj— e incorporan contexto inter-época (*lags*, *leads*, promedios móviles), clave en *sleep staging*. Sobre esas mismas *features* entrenamos además un **perceptrón multicapa** (MLP), que contrasta una red densa con los árboles con idéntica entrada (imputando los NaN de borde y estandarizando, pasos que XGBoost no requiere).

Frente a ellos, una **CNN 1D** opera sobre la señal cruda, con la hipótesis de aprender la dinámica temporal —incluida la variabilidad de alta frecuencia de la acelerometría que las *features* manuales descartan— sin *feature engineering*. Cada época se lleva a un tensor 150×4 (IHR interpolada y tres estadísticos por bin de 0,2s de la magnitud invariante: media, desvío y ENMO), que tres bloques convolucionales (Conv1D–BatchNorm–ReLU–pooling) más *global average pooling* y un clasificador denso mapean a las cinco etapas.

Los modelos anteriores clasifican cada época de forma aislada, ignorando que el sueño es una secuencia con fuerte estructura temporal. Para capturarla usamos una **LSTM bidireccional (BiLSTM)** [4], [5] *many-to-many*: procesa la noche completa como secuencia y emite una etapa por época. En

cada paso t , la celda LSTM regula un estado de memoria c_t mediante tres compuertas —entrada i_t , olvido f_t y salida o_t —:

$$\begin{aligned} (i_t, f_t, o_t) &= \sigma(W_{\{i,f,o\}} x_t + U_{\{i,f,o\}} h_{t-1} + b_{\{i,f,o\}}) \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad h_t = o_t \odot \tanh(c_t) \end{aligned} \quad (2)$$

donde σ es la sigmoide y $\odot$ el producto elemento a elemento. La variante **bidireccional** concatena una pasada hacia adelante y otra hacia atrás, $h_t = [\vec{h}_t; \overleftarrow{h}_t]$, de modo que cada época integra contexto pasado y futuro (en *sleep staging offline* se dispone de la noche completa); un cabezal lineal da la predicción por época $\hat{y}_t = \text{softmax}(Wh_t + b)$.

Por último, un **híbrido CNN–LSTM**, en la línea de SLAMSS [6], entrena ambos componentes *end-to-end*: la CNN 1D actúa como *encoder* intra-época —reemplaza la entrada x_t de la BiLSTM por el vector que aprende de la señal cruda de cada época— y la BiLSTM modela la dinámica inter-época sobre esa secuencia.

Todos los modelos neuronales se entrenan minimizando la *cross-entropy* ponderada por clase, $\mathcal{L} = -\sum_c w_c y_c \log \hat{y}_c$ con $w_c \propto 1/f_c$, para compensar el desbalance. En todos los casos la partición **agrupa por paciente**, para evitar *leakage* y medir la generalización a sujetos nuevos, descartando *Unknown*.

IV. RESULTADOS

IV-A. Análisis exploratorio y calidad de datos

La distribución de clases está fuertemente desbalanceada: N_2 (37,5 %) y REM (25,9 %) concentran la mayor parte de las épocas, seguidas de N_3 (18,5 %) y Wake (11,0 %), mientras que N_1 es marginal (7,1 %). Este desbalance justifica evaluar con $F1_{Macro}$, que pondera cada clase por igual, y compensar la frecuencia de clase durante el entrenamiento.




Figura 2. Ejemplo de procesamiento de una noche (Paciente 20, noche 1). La ventana válida (fondo verde) queda delimitada por el final de la continuidad de la acelerometría (IHR continúa) hasta las 7.94hs conservando 949/1282 épocas.

El control de calidad (Fig. 2) revela que **229 de 253 noches** (90.5 %) requieren alguna modificación —en su mayoría el trivial *signal_excess*— y que, al acotar la ventana válida por ambas señales (IHR y acelerometría), sólo **1** noche conserva un *internal_gap* genuino (P42 N4), que se descarta entera. La figura ilustra el procesamiento en una noche con *gaps* (P20 N1): la ventana válida (verde) conserva el tramo aprovechable

mientras se recorta la cola donde la acelerometría se interrumpe y aparecen *gaps* de señal (rojo), y el hipnograma procesado de **El acuerdo entre las etapas de los fuentes de etiquetado** (Ec. 1) fija el techo de la tarea: $\kappa = 0,74$ global, máximo en N_3 (0,90) y REM (0,85) y mínimo en N_1 (0,13), la etapa más fugaz y ambigua. Su matriz de confusión (Fig. ??) muestra que el desacuerdo entre el experto y Dreem se concentra en etapas contiguas (N_1 vs. N_2 y Wake), las transiciones intrínsecamente más ambiguas de discriminar.

IV-B. Clasificación

Los hiperparámetros de cada modelo se ajustan mediante **optimización bayesiana**: en lugar de una búsqueda exhaustiva (*grid search*) o aleatoria, se construye un modelo sustituto probabilístico de la métrica objetivo en función de los hiperparámetros y, en cada iteración, una función de adquisición propone la configuración más prometedora, equilibrando exploración y explotación. El objetivo optimizado es el $F1_{Macro}$ sobre la partición de *validación* —**agrupada por paciente**, igual que el resto del *pipeline*, para no introducir *leakage* en la selección— y la configuración ganadora se reentrena sobre *train* y se reporta una única vez sobre *test*. El espacio de búsqueda por modelo, el número de iteraciones y los valores finales seleccionados se detallan en la Tabla I.

El baseline XGBoost alcanza $F1_{Macro} = 0,47$ y $\kappa = 0,38$ (Ec. 1) frente al experto, con *accuracy* del 55 % (Tabla I). Pese al desbalance, capta señal discriminativa en las cinco clases, aunque lejos del techo humano ($\kappa = 0,74$); los errores se concentran entre etapas adyacentes (N_1 vs. N_2 y REM).

Cuadro I
RENDIMIENTO EN TEST (5 CLASES) FRENTE AL ETIQUETADO DEL EXPERTO.

Modelo	$F1_{acro}$	Cohen's κ	Accuracy
Dreem Label	—	0.74	—
XGBoost	0.4707	0.3776	—
MLP	—	—	—
BiLSTM	0.559	0.443	—
Híbrido	—	—	—

V. CONCLUSIÓN

Presentamos un *pipeline* de estadificación del sueño sobre señales de muñeca, del control de calidad a la clasificación. El acuerdo experto–Dreem ($\kappa = 0,74$) fija un techo realista y el baseline tabular ($F1_{Macro} = 0,47$, $\kappa = 0,38$) supera al azar pese al desbalance. La principal limitación del enfoque convolucional es la falta de contexto inter-época —clave en el tabular—, lo que motiva extenderlo a modelos recurrentes (LSTM/BiLSTM) sobre secuencias de épocas.

REFERENCIAS

[1] T.-A. Song, “A Multi-Night Instantaneous Heart Rate and Accelerometry Dataset with EEG Sleep Stage Labels,” *PhysioNet*, May 2026, version 1.0.0. [Online]. Available: <https://doi.org/10.13026/a0sy-7t69>

[2] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.

[3] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.

[4] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[5] M. Schuster and K. Paliwal, “Bidirectional recurrent neural networks,” *IEEE Transactions on Signal Processing*, vol. 45, no. 11, pp. 2673–2681, 1997.

[6] T.-A. Song, S. R. Chowdhury, M. Malekzadeh, S. Harrison, T. B. Hoge, S. Redline, K. L. Stone, R. Saxena, S. M. Purcell, and J. Dutta, “Ai-driven sleep staging from actigraphy and heart rate,” *PLOS ONE*, vol. 18, no. 5, pp. 1–29, 05 2023. [Online]. Available: <https://doi.org/10.1371/journal.pone.0285703>