

Predicción de Etapas del Sueño sobre señales Fisiológicas capturadas con SmartWatch

Agustín Adrián Pereyra
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apereyra@udesa.edu.ar

Agustín Patruno
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apatruno@udesa.edu.ar

Resumen—

Index Terms—sleep staging, recurrent neural networks, heart rate variability, accelerometry, EEG, deep learning

I. INTRODUCCIÓN

Frente a la polisomnografía —costosa y confinada al laboratorio—, los dispositivos *smart-watch* son capaces de registrar IHR (*Instantaneous Heart Rate*) y acelerometría de forma continua y no invasiva, habilitando el monitoreo domiciliario.

La *estadificación del sueño* (*sleep staging*) —asignar una etapa a cada época de 30 s de registro, según el estándar clínico AASM— es central para el diagnóstico de trastornos como la apnea o el insomnio, pero hoy depende de la polisomnografía y de la anotación manual de un experto, lo que la vuelve cara e incómoda. Lograrla a partir de señales de muñeca abriría la puerta a un monitoreo accesible y prolongado en el tiempo.

Abordamos la tarea como un problema de **clasificación multiclase supervisada**. La entrada de nuestro algoritmo es la IHR y la acelerometría triaxial de una época de 30 s (o su secuencia a lo largo de la noche), y utilizamos modelos de aprendizaje automático desde un *baseline* tabular (XGBoost, MLP) hasta modelos secuenciales que utilizan la señal cruda (BiLSTM y un híbrido CNN—BiLSTM) para predecir la etapa del sueño. Como referencia se emplean las etiquetas de un experto (*ground-truth*) y una referencia secundaria (y como nuestra competencia) las etiquetas de un dispositivo Dreem Headband, basado en EEG (electroencefalograma). El eje del trabajo es comparar esta progresión de modelos para cuantificar el aporte del **contexto temporal inter-época** —la dependencia entre etapas contiguas— frente a la clasificación de cada época de forma aislada.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

PhysioNet BIDSleep [1] recopila señales fisiológicas tales como la frecuencia cardíaca instantánea (IHR) y tres ejes de acelerometría medidas con un Apple Watch a lo largo de 253 noches de 47 adultos sanos. Cada lapso de 30 segundos se encuentra etiquetado por dos fuentes diferentes (*expert* y *dreem*) con una etapa del sueño:

0. **Wake** (Despierto)

1. **N1** (Sueño Ligero): etapa más superficial y la entrada al sueño. Suele ser la clase más difícil de detectar dado que es breve e inestable.
2. **N2** (Sueño Ligero consolidado): sujeto dormido de forma estable. Es la etapa más frecuente.
3. **N3** (Sueño profundo): el sueño más reparador. En él cuesta mucho despertar al paciente. Debería mostrar IHR mínimo y cuerpo inmóvil
4. **REM** (*Rapid Eye Movement*): también llamado “sueño paradójico”. El EEG se parece al de vigilia pero el paciente está profundamente dormido, involucrando IHR irregular.

La distribución de clases (label expert) está fuertemente desbalanceada: N_2 (37,5 %) y REM (25,9 %) concentran la mayor parte de las épocas, seguidas de N_3 (18,5 %) y Wake (11,0 %), mientras que N_1 es marginal (7,1 %). Este desbalance justifica evaluar con $F1_{Macro}$, que pondera cada clase por igual, como así la utilización de funciones de costo ponderadas por clase como realizamos en los modelos finales.

II-A. Procesamiento de la Señal

Realizamos una ardua y estricta limpieza de las señales dado que traían múltiples problemas:

- **Desalineación temporal**: el inicio de grabación viene en hora local (*America/New_York*) mientras que IHR y acelerometría están en Unix UTC. Se corrige convirtiendo el timestamp de inicio de grabación con su zona horaria antes de alinear señales y etiquetas.
- **Filas corruptas**: registros con *timestamps* inválidos se descartan filtrando $Timestamp > 10^9$.
- **Exceso de señal o de etiquetas en los bordes**: al inicio o al final de la noche una fuente puede cubrir un rango que las otras no. Como los modelos usan ambas señales, se define la **ventana válida** como la intersección entre el rango etiquetado y el de ambas señales continuas, recortando lo que sobre en cualquiera de los extremos.
- **Gaps internos** (*dropouts* reales del sensor): rompen la continuidad de la secuencia. Se resuelven recortando la cola cuando el prefijo limpio supera el 60 % (*trim_tail*) o descartando la noche entera si el hueco es interior/disperso.

- **Dropouts dispersos de acelerometría:** en vez de descartar la noche completa (demasiado agresivo), se filtra **por época**, descartando sólo las épocas sin cobertura suficiente de ambas señales.

En la Figura 1 se puede visualizar un ejemplo de cómo procesamos las señales de una noche completa.




Figura 1. Ejemplo de procesamiento de una noche (Paciente 20, noche 1). En verde la ventana válida —delimitada por el final de la continuidad de la acelerometría— y en rojo la zona problemática. La señal procesada finalmente dura hasta las 7.94hs conservando 949/1282 épocas.

Además para poder enviar a los modelos las señales crudas como entrada debimos realizar una representación acorde para que sea válida la señal en los modelos:

Como el IHR y la acelerometría se muestrean de forma irregular, cada época de 30s se lleva a una grilla fija de 150 *timesteps* (5 Hz, *bins* de 0,2s), obteniendo un tensor 150×4 . El primer canal es el IHR **interpolado linealmente** sobre la grilla; los otros tres se derivan de la **magnitud** $\|a\| = \sqrt{x^2 + y^2 + z^2}$ (invariante a la orientación del reloj): media y desvío estándar de $\|a\|$ por *bin* y media del **ENMO** (*Euclidean Norm Minus One*) = $\max(\|a\| - 1, 0)$, que aísla la aceleración por sobre la gravedad. Los *bins* de acelerometría vacíos se rellenan por *forward-fill*. Los cuatro canales se estandarizan con estadísticos de *train*, ya que el IHR domina en magnitud sobre el ENMO.

II-B. Extracción de Características

Para tener un enfoque tabular del conjunto de datos resumimos cada época de 30s en un vector de características *handcrafted*, diseñadas a partir del conocimiento del dominio. Se distinguen dos grupos.

Intra-época. De la IHR extraemos estadísticos de nivel y dispersión (media, mediana, desvío, rango intercuartílico y rango) junto con descriptores clásicos de la *variabilidad de la frecuencia cardíaca* (HRV) en el dominio del tiempo y la pendiente de la tendencia dentro de la época. Deliberadamente **no** incluimos las características espectrales de HRV (bandas LF: 0,04 Hz a 0,15 Hz y HF: 0,15 Hz a 0,4 Hz)¹: la IHR se

¹Las bandas LF (*Low Frequency*) y HF (*High Frequency*) son rangos de frecuencia del espectro de la HRV asociados a la actividad de los sistemas nerviosos simpático y parasimpático; su relación LF/HF es un indicador clásico del tono autonómico durante el sueño.

muestrea a $\approx 0,2$ Hz, por lo que la frecuencia de Nyquist² ($\approx 0,1$ Hz) cae por debajo de esas bandas y las vuelve físicamente inobservables. De la acelerometría, calculadas siempre sobre la **magnitud** $\|a\|$ para ser invariantes a la orientación del reloj, obtenemos la media y el desvío del ENMO, la dispersión y el rango de la magnitud, la fracción de inmovilidad (proporción de muestras con $\|a\| \approx 1g$) y la variabilidad del *jerk* (derivada de la magnitud).

Inter-época (contexto temporal). Como la etapa de sueño depende fuertemente de las épocas vecinas, cada característica intra-época se enriquece con su contexto: valores rezagados y adelantados, diferencias respecto de la época previa y estadísticos móviles (media y desvío en una ventana centrada), todo respetando los bordes de cada noche. Se añade además el tiempo transcurrido desde el último movimiento y la posición relativa de la época dentro de la noche.

Esto totaliza 122 características por época. Los valores indefinidos en los bordes (por los rezagos/adelantos) quedan como NaN, que XGBoost maneja de forma nativa y los modelos densos imputan.

II-C. Splitteo y Normalización

Con el fin de evitar *leakage* el conjunto se particiona **por paciente**, quedando 33 sujetos para el entrenamiento y luego 7 para la validación y 7 para el conjunto de test final. Luego ambas representaciones (tabular y señal cruda) se estandarizan con estadísticos de *train*; los modelos densos imputan a la mediana los NaN de borde.

III. METODOLOGÍA

III-A. Métricas de Rendimiento

Dado que se tienen dos criterios para tomar como *ground-truth* (etiquetas del experto y del dispositivo Dreem) usamos el **coeficiente Cohen's Kappa** [2] para cuantificar cuán de acuerdo están entre sí. [3]

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (1)$$

El desempeño de clasificación se mide con el **F1-score macro** —media del F1 por clase, que al pesar todas las etapas por igual es la métrica más honesta bajo el desbalance—, complementado con la **accuracy** global y la **matriz de confusión**, que localiza entre qué etapas ocurren los errores.

III-B. Elección de modelos

Como **baseline** se usa **XGBoost** sobre *features* por época: modelo tabular robusto, que maneja valores faltantes de forma nativa y da importancia interpretable. Las *features* resumen IHR y HRV en el dominio temporal (RMSSD, pNN50, etc.) y la acelerometría sobre la magnitud $\|a\|$ —invariante a la orientación del reloj— e incorporan contexto inter-época (*lags*, *leads*, promedios móviles), clave en *sleep staging*. Sobre esas

²Frecuencia máxima que una señal muestreada puede representar sin *aliasing*: la mitad de la frecuencia de muestreo. Para reconstruir un componente de f Hz hay que muestrear a más de $2f$ Hz.

mismas *features* entrenamos además un **perceptrón multicapa (MLP)**, que contrasta una red densa con los árboles con idéntica entrada (imputando los NaN de borde y estandarizando, pasos que XGBoost no requiere).

Frente a ellos, una **CNN 1D** opera sobre la señal cruda, con la hipótesis de aprender la dinámica temporal —incluida la variabilidad de alta frecuencia de la acelerometría que las *features* manuales descartan— sin *feature engineering*. Cada época se lleva a un tensor 150×4 (IHR interpolada y tres estadísticos por bin de 0,2s de la magnitud invariante: media, desvío y ENMO), que tres bloques convolucionales (Conv1D–BatchNorm–ReLU–pooling) más *global average pooling* y un clasificador denso mapean a las cinco etapas.

Los modelos anteriores clasifican cada época de forma aislada, ignorando que el sueño es una secuencia con fuerte estructura temporal. Para capturarla usamos una **LSTM bidireccional (BiLSTM)** [4], [5] *many-to-many*: procesa la noche completa como secuencia y emite una etapa por época. En cada paso t , la celda LSTM regula un estado de memoria c_t mediante tres compuertas —entrada i_t , olvido f_t y salida o_t —:

$$\begin{aligned}(i_t, f_t, o_t) &= \sigma(W_{\{i,f,o\}} x_t + U_{\{i,f,o\}} h_{t-1} + b_{\{i,f,o\}}) \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad h_t = o_t \odot \tanh(c_t)\end{aligned}\quad (2)$$

donde σ es la sigmoide y $\odot$ el producto elemento a elemento. La variante **bidireccional** concatena una pasada hacia adelante y otra hacia atrás, $h_t = [\vec{h}_t; \overleftarrow{h}_t]$, de modo que cada época integra contexto pasado y futuro (en *sleep staging offline* se dispone de la noche completa); un cabezal lineal da la predicción por época $\hat{y}_t = \text{softmax}(Wh_t + b)$.

Por último, un **híbrido CNN–LSTM**, en la línea de SLAMSS [6], entrena ambos componentes *end-to-end*: la CNN 1D actúa como *encoder* intra-época —reemplaza la entrada x_t de la BiLSTM por el vector que aprende de la señal cruda de cada época— y la BiLSTM modela la dinámica inter-época sobre esa secuencia.

Todos los modelos neuronales se entrenan minimizando la *cross-entropy* ponderada por clase, $\mathcal{L} = -\sum_c w_c y_c \log \hat{y}_c$ con $w_c \propto 1/f_c$, para compensar el desbalance. En todos los casos la partición **agrupa por paciente**, para evitar *leakage* y medir la generalización a sujetos nuevos, descartando *Unknown*.

IV. RESULTADOS

IV-A. Clasificación

Los hiperparámetros de cada modelo se ajustan mediante **optimización bayesiana**: en lugar de una búsqueda exhaustiva (*grid search*) o aleatoria, se construye un modelo sustituto probabilístico de la métrica objetivo en función de los hiperparámetros y, en cada iteración, una función de adquisición propone la configuración más prometedora, equilibrando exploración y explotación. El objetivo optimizado es el $F1_{Macro}$ sobre la partición de *validación* —**agrupada por paciente**, igual que el resto del *pipeline*, para no introducir *leakage* en la selección— y la configuración ganadora se reentrena sobre *train* y se reporta una única vez sobre *test*. El espacio de

búsqueda por modelo, el número de iteraciones y los valores finales seleccionados se detallan en la Tabla I.

El baseline XGBoost alcanza $F1_{Macro} = 0,44$ y $\kappa = 0,32$ (Ec. 1) frente al experto, con *accuracy* del 51 % (Tabla I). Pese al desbalance, capta señal discriminativa en las cinco clases, aunque lejos del techo humano ($\kappa = 0,74$); los errores se concentran entre etapas adyacentes (N_1 vs. N_2 y REM).

Cuadro I
RENDIMIENTO EN TEST (5 CLASES) FRENTE AL ETIQUETADO DEL EXPERTO.

Modelo	$F1_{macro}$	Cohen's κ	Accuracy
Dreem Label	0.7076	0.7173	0.7924
XGBoost	0.4450	0.3244	0.5063
MLP	0.4515	0.3475	0.5253
BiLSTM	0.5673	0.4630	0.5880
Híbrido	0.4773	0.3570	0.4795

Los dos *baselines* tabulares rinden de forma equivalente (XGBoost $\kappa = 0,32$, MLP $\kappa = 0,35$): la red densa no mejora a los árboles sobre las mismas *features*. La mayor mejora la aporta la **BiLSTM** ($F1_{Macro} = 0,57$, $\kappa = 0,463$), ~ 12 puntos de κ por encima, lo que confirma que el **contexto inter-época** es el factor determinante. El **híbrido** ($\kappa = 0,357$) se ubica por debajo pese a operar sobre la señal cruda, sin compensar las *features* diseñadas a mano. Todos los modelos permanecen lejos de la cota de referencia (Dreem, $\kappa = 0,717$): la brecha —limitación de las señales de muñeca frente al EEG— se concentra en N_1 y en las transiciones entre etapas contiguas. A continuación se presenta una segunda evaluación con 4 clases, agrupando N_1 y N_2 en *Light* y N_3 en *Deep*, por la similitud fisiológica entre esas etapas y para simplificar la tarea de clasificación.

Cuadro II
RENDIMIENTO EN TEST (4 CLASES) FRENTE AL ETIQUETADO DEL EXPERTO.

Modelo	$F1_{macro}$	Cohen's κ	Accuracy
Dreem Label	0.8457	0.8009	0.8669
XGBoost	0.5538	0.3363	0.5419
MLP	0.5681	0.3612	0.5600
BiLSTM	0.6500	0.4907	0.6519
Híbrido	0.5666	0.3927	0.5690

Al agrupar en 4 clases todas las métricas mejoran, dado que se elimina la confusión N_1-N_2 , la más frecuente. El ordenamiento entre modelos se mantiene: la **BiLSTM** continúa siendo el modelo de mejor desempeño ($F1_{Macro} = 0,65$, $\kappa = 0,49$) y el híbrido permanece por debajo, lo que confirma que la ventaja del contexto inter-época no depende de la granularidad del *target*. La brecha con la cota de referencia (Dreem, $\kappa = 0,80$) se reduce respecto de las 5 clases pero persiste, lo que evidencia que la limitación subyacente son las señales de muñeca y no la dificultad de separar N_1 de N_2 .

Como complemento a las métricas de decisión, la Tabla III reporta el promedio macro (one-vs-rest, 5 clases) del área bajo las curvas ROC (AUC) y Precision-Recall (AP), que evalúan la calidad del *ranking* de probabilidades de cada modelo con independencia del umbral de decisión.

Cuadro III
 PROMEDIO MACRO (ONE-VS-REST, 5 CLASES) DE LAS CURVAS ROC Y
 PRECISION-RECALL EN TEST.

Curva	XGBoost	MLP	BiLSTM	Híbrido
AUC-ROC macro	0.772	0.775	0.843	0.829
AP (PR) macro	0.488	0.497	0.603	0.569

Ambas curvas reproducen el mismo ordenamiento observado en las métricas de decisión: la BiLSTM lidera (AUC = 0,843, AP = 0,603), seguida del híbrido, con los baselines tabulares por detrás. La AP, más informativa bajo desbalance, se mantiene sensiblemente por debajo de la AUC en todos los modelos, lo que refleja la dificultad persistente en las clases minoritarias. Que la BiLSTM supere a los baselines también en la calidad del *ranking* —y no sólo en la decisión final— indica que el contexto inter-época mejora la confianza asignada a cada etapa, no únicamente el umbral de corte.

V. CONCLUSIÓN

Presentamos un *pipeline* de estadificación del sueño sobre señales de muñeca, del control de calidad a la clasificación. El acuerdo experto–Dreem ($\kappa = 0,74$) fija un techo realista y el baseline tabular ($F1_{Macro} = 0,47$, $\kappa = 0,38$) supera al azar pese al desbalance. La principal limitación del enfoque convolucional es la falta de contexto inter-época —clave en el tabular—, lo que motiva extenderlo a modelos recurrentes (LSTM/BiLSTM) sobre secuencias de épocas.

REFERENCIAS

- [1] T.-A. Song, “A Multi-Night Instantaneous Heart Rate and Accelerometry Dataset with EEG Sleep Stage Labels,” *PhysioNet*, May 2026, version 1.0.0. [Online]. Available: <https://doi.org/10.13026/a0sy-7t69>
- [2] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [3] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [4] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [5] M. Schuster and K. Paliwal, “Bidirectional recurrent neural networks,” *IEEE Transactions on Signal Processing*, vol. 45, no. 11, pp. 2673–2681, 1997.
- [6] T.-A. Song, S. R. Chowdhury, M. Malekzadeh, S. Harrison, T. B. Hoge, S. Redline, K. L. Stone, R. Saxena, S. M. Purcell, and J. Dutta, “Ai-driven sleep staging from actigraphy and heart rate,” *PLOS ONE*, vol. 18, no. 5, pp. 1–29, 05 2023. [Online]. Available: <https://doi.org/10.1371/journal.pone.0285703>