

Predicción de Etapas del Sueño sobre señales Fisiológicas con RNNs

Agustín Adrián Pereyra
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apereyra@udesa.edu.ar

Agustín Patruno
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apatruno@udesa.edu.ar

Resumen—

Index Terms—sleep staging, recurrent neural networks, heart rate variability, accelerometry, EEG, deep learning

I. Introducción

Frente a la polisomnografía – costosa y confinada al laboratorio –, los dispositivos smart-watch son capaces de registrar IHR (Instantaneous Heart Rate) y acelerometría de forma continua y no invasiva, habilitando el monitoreo domiciliario.

La estadificación del sueño (sleep staging) –asignar una etapa a cada época de 30 s de registro, según el estándar clínico AASM– es central para el diagnóstico de trastornos como la apnea o el insomnio, pero hoy depende de la polisomnografía y de la anotación manual de un experto, lo que la vuelve cara e incómoda. Lograrla a partir de señales de muñeca abriría la puerta a un monitoreo accesible y prolongado en el tiempo.

Abordamos la tarea como un problema de clasificación multiclase supervisada. La entrada de nuestro algoritmo es la IHR y la acelerometría triaxial de una época de 30 s (o su secuencia a lo largo de la noche), y utilizamos modelos de aprendizaje automático –desde un baseline tabular (XGBoost, MLP) hasta redes sobre la señal cruda (CNN 1D) y modelos secuenciales (LSTM/BiLSTM y un híbrido CNN–LSTM)– para predecir la etapa del sueño {Wake, N_1 , N_2 , N_3 , REM}. Como referencia se emplean las etiquetas de un experto (ground-truth) y las del dispositivo Dreem, basado en EEG. El eje del trabajo es comparar esta progresión de modelos para cuantificar el aporte del contexto temporal inter-época –la dependencia entre etapas contiguas– frente a la clasificación de cada época de forma aislada.

La Fig. 1 muestra un ejemplo de la entrada: las señales de IHR y acelerometría de una noche completa junto al hipnograma de referencia. Ya se aprecia la estructura cíclica del sueño –la IHR desciende y se estabiliza en sueño profundo (N_3) y se vuelve más variable en REM, mientras que la acelerometría sólo registra actividad en las transiciones a vigilia–, correspondencia que hace la tarea abordable a partir de datos de muñeca.




Figura 1. Ejemplo de la entrada del algoritmo: señales (IHR y acelerometría) e hipnograma de una noche completa (Paciente 00, Noche 1).

II. Conjunto de Datos y Características

PhysioNet BIDSleep [1] recopila señales fisiológicas tales como la frecuencia cardíaca instantánea (IHR) y 3 ejes de acelerometría medidas con un Apple Watch a lo largo de 253 noches de 47 adultos sanos. Cada lapso de 30 segundos se encuentra etiquetado, por dos fuentes diferentes, como una etapa del sueño: {0:Wake, 1: N_1 , 2: N_2 , 3: N_3 , 4:REM, 5:Unknown}

El experto define la variable objetivo (Dreem queda como referencia independiente) y se descarta la clase Unknown. La partición es por paciente –evita leakage y mide la generalización a sujetos nuevos–: del corpus válido ($\approx 208k$ épocas), 123 495/37 566/47 427 en train/val/test (29/8/10 pacientes) para los modelos tabulares y 33/7/7 sujetos para los secuenciales.

Se emplean dos representaciones: una tabular de 122 features por época y la señal cruda 150×4 en secuencias por noche, ambas estandarizadas con estadísticos de train; los modelos densos imputan a la mediana los NaN de borde. El IHR se muestrea a $\approx 0,2$ Hz (Nyquist $\approx 0,1$ Hz), por debajo de las bandas LF/HF (0,04–0,4 Hz), que resultan inobservables.

Antes de modelar se aplica un control de calidad noche a noche. Sobre cada noche se computan gaps temporales en IHR y acelerometría ($> 60s$ entre muestras),

duración de la señal y fracción de acelerometría inválida ($||a|| - 1| > 0,5g$), y se define la ventana válida como la intersección entre el rango etiquetado y el de IHR continua. Los desajustes se clasifican en `signal_excess` (señal sin etiqueta, se recorta), `label_trunc` (etiqueta sin señal, se recorta) e `internal_gap` (huecos > 10 min). Estos últimos, verificados como dropouts reales del sensor, se resuelven recortando la cola si el prefijo limpio supera el 60 % o descartando la noche. Todo se aplica en memoria, sin alterar los archivos originales.

III. Metodología

III-A. Métricas de Rendimiento

Dado que se tienen dos criterios para tomar como ground-truth (etiquetas del experto y del dispositivo Dreem) usamos el coeficiente Cohen's Kappa [2] para cuantificar cuán de acuerdo están entre sí. [3]

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (1)$$

El desempeño de clasificación se mide con el F1-score macro —media del F1 por clase, que al pesar todas las etapas por igual es la métrica más honesta bajo el desbalance—, complementado con la accuracy global y la matriz de confusión, que localiza entre qué etapas ocurren los errores.

III-B. Elección de modelos

Como baseline se usa XGBoost sobre features por época: modelo tabular robusto, que maneja valores faltantes de forma nativa y da importancia interpretable. Las features resumen IHR y HRV en el dominio temporal (RMSSD, pNN50, etc.) y la acelerometría sobre la magnitud $||a||$ —invariante a la orientación del reloj— e incorporan contexto inter-época (lags, leads, promedios móviles), clave en sleep staging. Sobre esas mismas features entrenamos además un perceptrón multicapa (MLP), que contrasta una red densa contra los árboles con idéntico input (imputando los NaN de borde y estandarizando, pasos que XGBoost no requiere).

Frente a ellos, una CNN 1D opera sobre la señal cruda, con la hipótesis de aprender la dinámica temporal —incluida la variabilidad de alta frecuencia de la acelerometría que las features manuales descartan— sin feature engineering. Cada época se lleva a un tensor 150×4 (IHR interpolada y tres estadísticos por bin de 0,2s de la magnitud invariante: media, desvío y ENMO), que tres bloques convolucionales (Conv1D–BatchNorm–ReLU–pooling) más global average pooling y un clasificador denso mapean a las cinco etapas.

Los modelos anteriores clasifican cada época de forma aislada, ignorando que el sueño es una secuencia con fuerte estructura temporal. Para capturarla usamos una LSTM bidireccional (BiLSTM) [4], [5] many-to-many: procesa la noche completa como secuencia y emite una etapa por época. En cada paso t , la celda LSTM regula un estado

de memoria c_t mediante tres compuertas —entrada i_t , olvido f_t y salida o_t —:

$$\begin{aligned} (i_t, f_t, o_t) &= \sigma(W_{\{i,f,o\}} x_t + U_{\{i,f,o\}} h_{t-1} + b_{\{i,f,o\}}) \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad h_t = o_t \odot \tanh(c_t) \end{aligned} \quad (2)$$

donde σ es la sigmoide y $\odot$ el producto elemento a elemento. La variante bidireccional concatena una pasada hacia adelante y otra hacia atrás, $h_t = [\vec{h}_t; \overleftarrow{h}_t]$, de modo que cada época integra contexto pasado y futuro (en sleep staging offline se dispone de la noche completa); un cabezal lineal da la predicción por época $\hat{y}_t = \text{softmax}(Wh_t + b)$.

Por último, un híbrido CNN–LSTM, en la línea de SLAMSS [6], entrena ambos componentes end-to-end: la CNN 1D actúa como encoder intra-época —reemplaza la entrada x_t de la BiLSTM por el vector que aprende de la señal cruda de cada época— y la BiLSTM modela la dinámica inter-época sobre esa secuencia.

Todos los modelos neuronales se entrenan minimizando la cross-entropy ponderada por clase, $\mathcal{L} = -\sum_c w_c y_c \log \hat{y}_c$ con $w_c \propto 1/f_c$, para compensar el desbalance. En todos los casos la partición agrupa por paciente, para evitar leakage y medir la generalización a sujetos nuevos, descartando Unknown.

IV. Resultados

IV-A. Análisis exploratorio y calidad de datos

La distribución de clases (Fig. ??) está fuertemente desbalanceada: N_2 y Wake concentran la mayor parte de las épocas mientras que N_1 es marginal. Este desbalance justifica evaluar con $F1_{Macro}$, que pondera cada clase por igual, y compensar la frecuencia de clase durante el entrenamiento.




Figura 2. Noches con pérdida de labels o gaps internos: en verde la ventana válida; en naranja los labels recortados; en rojo los gaps.

El control de calidad (Fig. 2) revela que 228 de 253 noches (90.1 %) requieren alguna modificación —en su mayoría el trivial `signal_excess`— y que sólo 4 presentan

internal_gap. La figura ilustra cómo la ventana válida (verde) recupera el tramo aprovechable de cada noche, descartando los labels sin señal (naranja) y los huecos internos (rojo) que romperían la continuidad temporal.




Figura 3. Matriz de confusión experto vs. Dreem; el desacuerdo se concentra en etapas adyacentes.

El acuerdo entre las dos fuentes de etiquetado (Ec. 1) fija el techo de la tarea: $\kappa = 0,74$ global, máximo en REM (0,85) y menor en Wake (0,70). Su matriz de confusión (Fig. 3) muestra que el desacuerdo entre el experto y Dreem se concentra en etapas contiguas (N_1 vs. N_2 y Wake), las transiciones intrínsecamente más ambiguas de discriminar.

IV-B. Clasificación

El baseline XGBoost alcanza $F1_{Macro} = 0,47$ y $\kappa = 0,38$ (Ec. 1) frente al experto, con accuracy del 55 % (Tabla I). Pese al desbalance, capta señal discriminativa en las cinco clases, aunque lejos del techo humano ($\kappa = 0,74$); los errores se concentran entre etapas adyacentes (N_1 vs. N_2 y REM).

Cuadro I

Rendimiento en test (5 clases) frente al etiquetado del experto.

Modelo	$F1_{Macro}$	Cohen's κ
Dreem Label	—	0.74
XGBoost(features)	0.4707	0.3776
XGBoost(embeddings)	0.3971	0.2867
XGBoost(features+embeddings)	0.4686	0.3762
MLP(features)		
LSTM(Identity)	0.559	0.443
LSTM(CNN1d)		

V. Conclusión

Presentamos un pipeline de estadificación del sueño sobre señales de muñeca, del control de calidad a la clasificación. El acuerdo experto–Dreem ($\kappa = 0,74$) fija un techo

realista y el baseline tabular ($F1_{Macro} = 0,47$, $\kappa = 0,38$) supera al azar pese al desbalance. La principal limitación del enfoque convolucional es la falta de contexto inter-época —clave en el tabular—, lo que motiva extenderlo a modelos recurrentes (LSTM/BiLSTM) sobre secuencias de épocas.

Referencias

- [1] T.-A. Song, “A Multi-Night Instantaneous Heart Rate and Accelerometry Dataset with EEG Sleep Stage Labels,” PhysioNet, May 2026, version 1.0.0. [Online]. Available: <https://doi.org/10.13026/a0sy-7t69>
- [2] J. Cohen, “A coefficient of agreement for nominal scales,” Educational and Psychological Measurement, vol. 20, no. 1, pp. 37–46, 1960.
- [3] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” Biometrics, vol. 33, no. 1, pp. 159–174, 1977.
- [4] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997.
- [5] M. Schuster and K. Paliwal, “Bidirectional recurrent neural networks,” IEEE Transactions on Signal Processing, vol. 45, no. 11, pp. 2673–2681, 1997.
- [6] T.-A. Song, S. R. Chowdhury, M. Malekzadeh, S. Harrison, T. B. Hoge, S. Redline, K. L. Stone, R. Saxena, S. M. Purcell, and J. Dutta, “Ai-driven sleep staging from actigraphy and heart rate,” PLOS ONE, vol. 18, no. 5, pp. 1–29, 05 2023. [Online]. Available: <https://doi.org/10.1371/journal.pone.0285703>