

Predicción de Etapas del Sueño sobre señales Fisiológicas con RNNs

Agustín Adrián Pereyra
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apereyra@udesa.edu.ar

Agustín Patruno
Departamento de Ingeniería
Universidad de San Andrés
Buenos Aires, Argentina
apatruno@udesa.edu.ar

Resumen—

Index Terms—sleep staging, recurrent neural networks, heart rate variability, accelerometry, EEG, deep learning

I. Introducción

Frente a la polisomnografía – costosa y confinada al laboratorio –, los dispositivos smart-watch son capaces de registrar IHR (Instantaneous Heart Rate) y acelerometría de forma continua y no invasiva, habilitando el monitoreo domiciliario.

II. Conjunto de Datos y Características

PhysioNet BIDSleep [1] recopila señales fisiológicas tales como la frecuencia cardíaca instantánea (IHR) y 3 ejes de acelerometría medidas con un Apple Watch a lo largo de 253 noches de 47 adultos sanos. Cada lapso de 30 segundos se encuentra etiquetado, por dos fuentes diferentes, como una etapa del sueño: {0:Wake, 1: N_1 , 2: N_2 , 3: N_3 , 4:REM, 5:Unknown}

III. Metodología

III-A. Métricas de Rendimiento

Dado que se tienen dos criterios para tomar como ground-truth (etiquetas del experto y del dispositivo Dreem) usamos el coeficiente Cohen’s Kappa [2] para cuantificar cuán de acuerdo están entre sí. [3]

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (1)$$

El desempeño de clasificación se mide con el F1-score macro —media del F1 por clase, que al pesar todas las etapas por igual es la métrica más honesta bajo el desbalance—, complementado con la accuracy global y la matriz de confusión, que localiza entre qué etapas ocurren los errores.

III-B. Limpieza de señales

Antes de modelar se aplica un control de calidad noche a noche. Sobre cada noche se computan gaps temporales en IHR y acelerometría ($> 60s$ entre muestras), duración de la señal y fracción de acelerometría inválida ($(\|a\| - 1) > 0,5g$), y se define la ventana válida como la intersección entre el rango etiquetado y el de IHR

continua. Los desajustes se clasifican en `signal_excess` (señal sin etiqueta, se recorta), `label_trunc` (etiqueta sin señal, se recorta) e `internal_gap` (huecos > 10 min). Estos últimos, verificados como dropouts reales del sensor, se resuelven recortando la cola si el prefijo limpio supera el 60 % o descartando la noche. Todo se aplica en memoria, sin alterar los archivos originales.

III-C. Elección de modelos

Como baseline se usa XGBoost sobre features por época: modelo tabular robusto, que maneja valores faltantes de forma nativa y da importancia interpretable. Las features resumen IHR y HRV en el dominio temporal (RMSSD, pNN50, etc.) y la acelerometría sobre la magnitud $\|a\|$ —invariante a la orientación del reloj— e incorporan contexto inter-época (lags, leads, promedios móviles), clave en sleep staging.

Frente a él, una CNN 1D opera sobre la señal cruda, con la hipótesis de aprender la dinámica temporal —incluida la variabilidad de alta frecuencia de la acelerometría que las features manuales descartan— sin feature engineering. Cada época se lleva a un tensor 150×4 (IHR interpolada y tres estadísticos por bin de 0,2s de la magnitud invariante: media, desvío y ENMO), que tres bloques convolucionales (Conv1D–BatchNorm–ReLU–pooling) más global average pooling y un clasificador denso mapean a las cinco etapas; el desbalance se compensa ponderando la cross-entropy por la frecuencia inversa de clase. En ambos casos la partición agrupa por paciente para evitar leakage y medir generalización a sujetos nuevos, descartando Unknown.

IV. Resultados

IV-A. Análisis exploratorio y calidad de datos




Figura 1. Representación visual de una noche completa (Paciente 00, Noche 1)

La Fig. Representación visual de una noche completa (Paciente 00, Noche 1) muestra las señales de una noche completa, donde se aprecia la estructura cíclica del sueño: la IHR desciende y se estabiliza en los tramos de sueño profundo (N_3) y se torna más variable en REM mientras que la acelerometría sólo registra actividad marcada en las transiciones a vigilia. Esta correspondencia entre la dinámica de las señales y el hipnograma es la que hace la tarea abordable a partir de datos de muñeca.

La distribución de clases (Fig. ??) está fuertemente desbalanceada: N_2 y Wake concentran la mayor parte de las épocas mientras que N_1 es marginal. Este desbalance justifica evaluar con $F1_{Macro}$, que pondera cada clase por igual, y compensar la frecuencia de clase durante el entrenamiento.




Figura 2. Noches con pérdida de labels o gaps internos: en verde la ventana válida; en naranja los labels recortados; en rojo los gaps.

El control de calidad (Fig. Noches con pérdida de labels o gaps internos: en verde la ventana válida; en naranja

los labels recortados; en rojo los gaps) revela que 228 de 253 noches (90.1 %) requieren alguna modificación —en su mayoría el trivial `signal_excess`— y que sólo 4 presentan `internal_gap`. La figura ilustra cómo la ventana válida (verde) recupera el tramo aprovechable de cada noche, descartando los labels sin señal (naranja) y los huecos internos (rojo) que romperían la continuidad temporal.




Figura 3. Matriz de confusión experto vs. Dreem; el desacuerdo se concentra en etapas adyacentes.

El acuerdo entre las dos fuentes de etiquetado (Ec. Métricas de Rendimiento) fija el techo de la tarea: $\kappa = 0,74$ global, máximo en REM (0,85) y menor en Wake (0,70). Su matriz de confusión (Fig. Matriz de confusión experto vs. Dreem; el desacuerdo se concentra en etapas adyacentes) muestra que el desacuerdo entre el experto y Dreem se concentra en etapas contiguas (N_1 vs. N_2 y Wake), las transiciones intrínsecamente más ambiguas de discriminar.

IV-B. Clasificación

El baseline XGBoost alcanza $F1_{Macro} = 0,47$ y $\kappa = 0,38$ (Ec. Métricas de Rendimiento) frente al experto, con accuracy del 55 % (Tabla Rendimiento en test (5 clases) frente al etiquetado del experto). Pese al desbalance, capta señal discriminativa en las cinco clases, aunque lejos del techo humano ($\kappa = 0,74$); los errores se concentran entre etapas adyacentes (N_1 vs. N_2 y REM).

V. Conclusión

Presentamos un pipeline de estadificación del sueño sobre señales de muñeca, del control de calidad a la clasificación. El acuerdo experto–Dreem ($\kappa = 0,74$) fija un techo realista y el baseline tabular ($F1_{Macro} = 0,47$, $\kappa = 0,38$) supera al azar pese al desbalance. La principal limitación del enfoque convolucional es la falta de contexto inter-época —clave en el tabular—, lo que motiva extenderlo

Cuadro I

Rendimiento en test (5 clases) frente al etiquetado del experto.

Modelo	$F1_{Macro}$	Cohen's κ
Dream Label	—	0.74
XGBoost(features)	0.4707	0.3776
XGBoost(embeddings)	0.3971	0.2867
XGBoost(features+embeddings)	0.4686	0.3762
MLP(features)		
LSTM(Identity)	0.559	0.443
LSTM(CNN1d)		

a modelos recurrentes (LSTM/BiLSTM) sobre secuencias de épocas.

Referencias

- [1] T.-A. Song, “A Multi-Night Instantaneous Heart Rate and Accelerometry Dataset with EEG Sleep Stage Labels,” PhysioNet, May 2026, version 1.0.0. [Online]. Available: <https://doi.org/10.13026/a0sy-7t69>
- [2] J. Cohen, “A coefficient of agreement for nominal scales,” Educational and Psychological Measurement, vol. 20, no. 1, pp. 37–46, 1960.
- [3] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” Biometrics, vol. 33, no. 1, pp. 159–174, 1977.