

Worklog

1. Dataset

1.1. Sitios Webs

- Papers With Code – Datasets — Datasets tabulares con papers y métricas de referencia asociadas.
- OpenML — Repositorio de datasets para benchmarking, con resultados comparativos públicos.
- Kaggle Datasets — Datasets de competencias con notebooks y baselines de referencia.
- UCI ML Repository — Colección clásica de datasets para investigación en ML.
- Hugging Face Datasets — Repositorio creciente con datasets vinculados a papers recientes.
- NASA Earthdata — Datos climáticos, atmosféricos y oceánicos de misiones de la NASA.
- NOAA Climate Data — Datos meteorológicos y climáticos históricos reales.
- CERN Open Data Portal — Datos de física de partículas del acelerador LHC.
- PANGAEA — Datos de ciencias del mar y la tierra asociados a publicaciones científicas.
- PhysioNet — Datos clínicos reales con papers asociados (UCI hospitalaria, señales fisiológicas).
- NIH GDC — Datos genómicos y clínicos de investigación oncológica.
- CDC BRFSS — Encuestas de salud poblacional de EE.UU., ampliamente usadas en ML clínico.
- Global Health Observatory – OMS — Indicadores de salud pública por país.
- IPUMS — Microdatos censales de todo el mundo, incluyendo América Latina.
- Our World in Data — Datos globales sobre pobreza, energía, educación y salud con papers detrás.
- World Bank Open Data — Indicadores económicos y sociales por país.
- Data.gov — Más de 290k datasets de agencias federales de EE.UU.
- datos.gob.ar — Portal de datos abiertos del gobierno argentino.
- EU Open Data Portal — Datos abiertos de la Unión Europea.
- Zenodo — Repositorio del CERN: cada dataset tiene DOI y referencia directa a su paper.
- Figshare — Datos publicados junto a artículos científicos de múltiples disciplinas.
- Dryad — Datasets de papers de ciencias biológicas y ambientales.
- Harvard Dataverse — Repositorio de Harvard con datos de investigación de todas las disciplinas.

1.2. Datasets Candidatos

Dataset	Descripción	n	m	Objetivo
phenomene	Sonidos nasales y orales. Amplitudes de armónicos.	5404	5	Clasificación Binaria
cardiotocography	Cardiotocogramas (CTG) fetales para clasificación de patrón morfológico y de estado fetal.	2126	36	Clasificación Multiclase (10 o 3)
steam-games-dataset	Información de juegos publicados en Steam	124.146	41	Clasificación / Regresión
volcanoes-c1 ¹	Imágenes de la superficie de Venus obtenidas de SAR (Synthetic Aperture Radar).	28.626	–	Clasificación Multiclase (4)
bidlab	Registros de frecuencia cardíaca instantánea y ejes de acelerometría para identificación de fases de sueño. Datos de 47 adultos de 3–8 noches, datos temporales .	–	4	Clasificación Multiclase
hillel-yaffe-glaucoma	Imágenes de fondos de ojos para detección de glaucomas.	747	–	Clasificación Binaria

¹Hay varios experimentos del mismo, buscar **volcanoes** en OpenML, este es el de mayor cantidad de muestras